Web Mining Project

Interfacce:

1. **Source**: Definisce un'interfaccia per le diverse fonti di dati, come CSV, API di The Guardian o altre fonti future.
2. **ArticleStorage**: Definisce un'interfaccia per la memorizzazione degli articoli scaricati.
3. **TermExtraction**: Definisce un'interfaccia per l'estrazione dei termini dai testi degli articoli.
4. **TermStorage**: Definisce un'interfaccia per la memorizzazione dei termini estratti.

Classi:

1. **Article**: Rappresenta un singolo articolo con attributi come "title" e "bodyText".
2. **CSVSource**: Implementa l'interfaccia "Source" per il download degli articoli da un file CSV.
3. **TheGuardianAPISource**: Implementa l'interfaccia "Source" per il download degli articoli dall'API di The Guardian.
4. **FileArticleStorage**: Implementa l'interfaccia "ArticleStorage" per la memorizzazione degli articoli in un file utilizzando un formato txt.
5. **Term:** Rappresenta un singolo termine con attributi come “term” (la stringa che compone il termine) e “weight”
6. **NLPTermExtraction**: Implementa l'interfaccia "TermExtraction" utilizzando una libreria NLP come CoreNLP, Apache OpenNLP o Stanford NLP per l'elaborazione del testo e l'estrazione dei termini.
7. **FileTermStorage:** Implementa l'interfaccia "TermStorage" per la memorizzazione dei termini in un file di testo utilizzando un formato specificato.
8. **App** (classe principale): Punto di ingresso dell'applicazione che coordina il download, l'estrazione dei termini e la memorizzazione degli articoli.

Suddivisione:

- Termini: Veronica Cisotto
- Storage articoli e termini: Marco Toffoletto
- Download/Parsing: Ho Van Sang

Librerie e Maven:

- **CoreNLP**: Tokenizzazione ed estrazione termini

  I.
```
<!-- CoreNLP -->
<dependency>
    <groupId>edu.stanford.nlp</groupId>
    <artifactId>stanford-corenlp</artifactId>
    <version>4.5.4</version>
</dependency>
```

- **Apache common CSV**: gestione file csv

  II.
```
<!-- Apache commons CSV -->
<dependency>
    <groupId>org.apache.commons</groupId>
    <artifactId>commons-csv</artifactId>
    <version>1.10.0</version>
</dependency>
```

- **Guardian API**: gestione file json

III.
```
<!-- Guardian API -->
<dependency>
    <groupId>com.google.code.gson</groupId>
    <artifactId>gson</artifactId>
    <version>2.10</version>
</dependency>
<dependency>
    <groupId>org.apache.httpcomponents</groupId>
    <artifactId>httpclient</artifactId>
    <version>4.5.14</version>
</dependency>
```

- **JUnit:** testing

IV.
```
<!-- Junit Testing -->
<dependency>
    <groupId>junit</groupId>
    <artifactId>junit</artifactId>
    <version>4.13.2</version>
    <scope>test</scope>
</dependency>
<dependency>
    <groupId>org.junit.jupiter</groupId>
    <artifactId>junit-jupiter</artifactId>
    <version>RELEASE</version>
    <scope>test</scope>
</dependency>
```